课程项目 · 音乐 AI · 2026

一个项目，两个任务，五个负结果

音乐流派分类 × 音频 Token 预测

GTZAN 985 · FMA-small 7,994 · 6 模型 · 3 种子 · 42 页报告

组员 梁煜炜 · 贾智涵 · 王薪羽 · 陈泽玉

同一批音乐，模型能听懂多少？

p(流派 | 音频)

判别式　答对几成　Macro-F1

p(下一个 Token | 前 5 秒)

生成式　离真相多远　Top-1 / Log-Mel RMSE

同一份数据划分 · 同一批测试曲目 · 指标不可比

数据从哪来： 985 首，和 7,994 首

	GTZAN	FMA-small
曲目	985	7,994
类别	10	8
训练 / 验证 / 测试	690 / 147 / 147	5,596 / 1,199 / 1,199
模型输入	中心 5 秒	中心 5 秒
采样率	22.05 kHz	22.05 kHz

素材本身是 30 秒，但模型全程只听中心 5 秒。

来源： docs/repo_overview.md §2 · 报告 §3.4

一个很容易做错的划分

0.470 → 0.568

同一批特征	209 维人工特征，一个都没换
同一个 CNN	同一份权重、同一个种子
换的只是划分	「按艺术家划分」→「按曲目划分」

81.0% 的测试曲与训练集共享艺术家

来源：报告 §3.4 表 4

三条比赛规则

01

三个种子，报均值

42 / 123 / 2024 ，不挑最好的那一次

02

验证集选型，测试集只评一次

评完不许回头改参数

03

按艺术家划分

同一个人只出现在训练或测试一边

来源：data/splits/*/splits.csv（全模型共用）

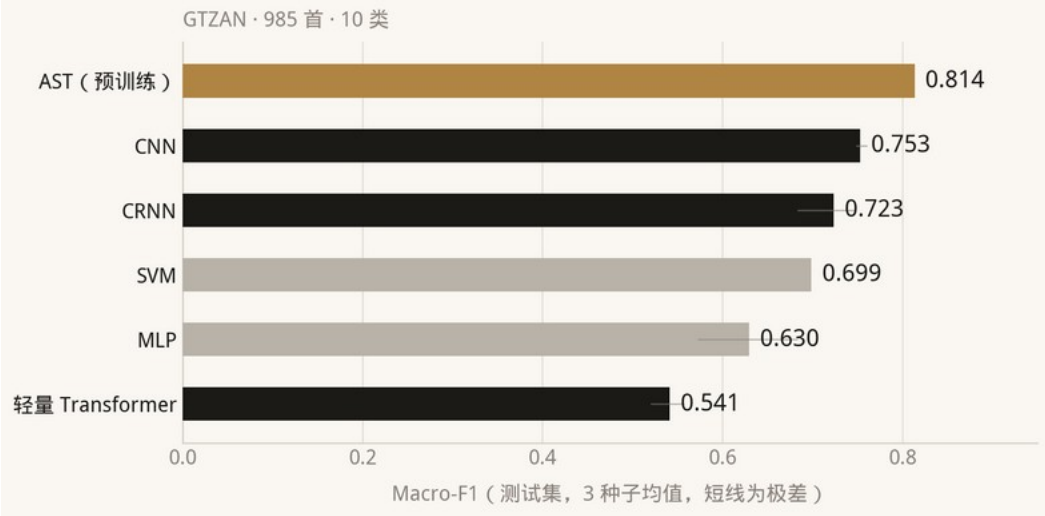
六位选手

选手	输入	参数量	体积定位
SVM	209 维人工特征	—	1.2 MB老派，抗造
MLP	209 维人工特征	8.8 万	1.1 MB略弱于 SVM
CNN	64×216 log-Mel	59 万	2.4 MB自建冠军（GTZAN）
CRNN	同上 + BiGRU	42 万	1.7 MB数据够了才反超
轻量 Transformer	同上 + 位置编码	65 万	1.2 MB千首级过拟合
AST	128×1024 log-Mel	8,600 万（冻结）	346 MB预训练，两榜第一

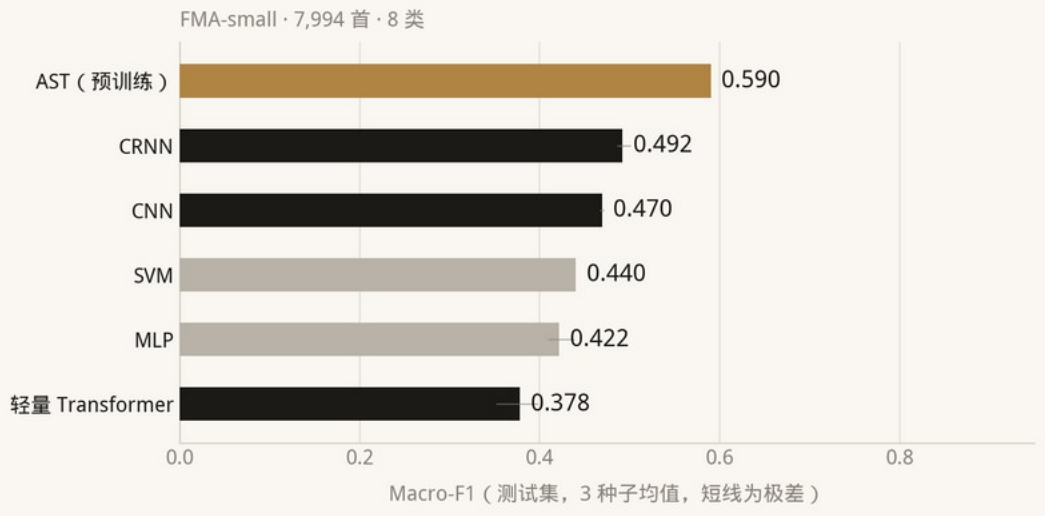
AST 为冻结主干 + 线性头（7,690 参数），不是微调。

来源：results/gtzan/metrics.csv · 报告 §5.1

六位选手的成绩单



GTZAN · 985 首 · 10 类



FMA-small · 7,994 首 · 8 类

.814

AST · GTZAN

.590

AST · FMA-small

.542

轻量 Transformer · 两榜垫底

来源：results/gtzan/metrics.csv · results/fma/metrics.csv（3 种子均值）

冠军的代价



延迟与体积，双对数坐标（ GTZAN 测试集实测）

270×

延迟： 0.76 → 204 ms

145×

体积： 2.4 → 346 MB

离线批处理可接受，
实时交互不可用。

来源：报告 §5.4 · results/gtzan/metrics.csv

同一首歌，六种判断

六个模型、同一批曲目、各自投票——内部管这个设定叫「 PVP 擂台」

曲目	真值	SVM	MLP	CNN	CRNN	TF
073776	International	Instrumental ✗ 23%	Folk ✗ 35%	Experimental ✗ 43%	Electronic ✗ 91%	Pop ✗ 29%
classical.00099	classical	classical ✓ 82%	classical ✓ 100%	rock ✗ 77%	country ✗ 70%	jazz ✗ 46%
blues.00012	blues	blues ✓ 65%	blues ✓ 98%	blues ✓ 85%	blues ✓ 97%	blues ✓ 97%

5 秒 · FMA 测试集 · 模型没见过

来源： results/fma/predictions/*_seed42_test.csv

模型不是白纸

模型	生来就信的假设	数据少时	数据多时
SVM / MLP	自己没有先验，但输入的人工特征里全是	稳，天花板低	天花板低
CNN	**局部性 + 平移等变**	强	强
CRNN	**局部性 + 循环层的记忆**	稍弱	更强
轻量 Transformer	**只有位置编码，几乎没有结构先验**	严重过拟合	待观察
AST	**架构同上，预训练把先验灌进权重**	最强	最强

先验越少，样本效率越低；先验越少，天花板越高。这是一枚硬币的两面。

来源：报告 §7.6

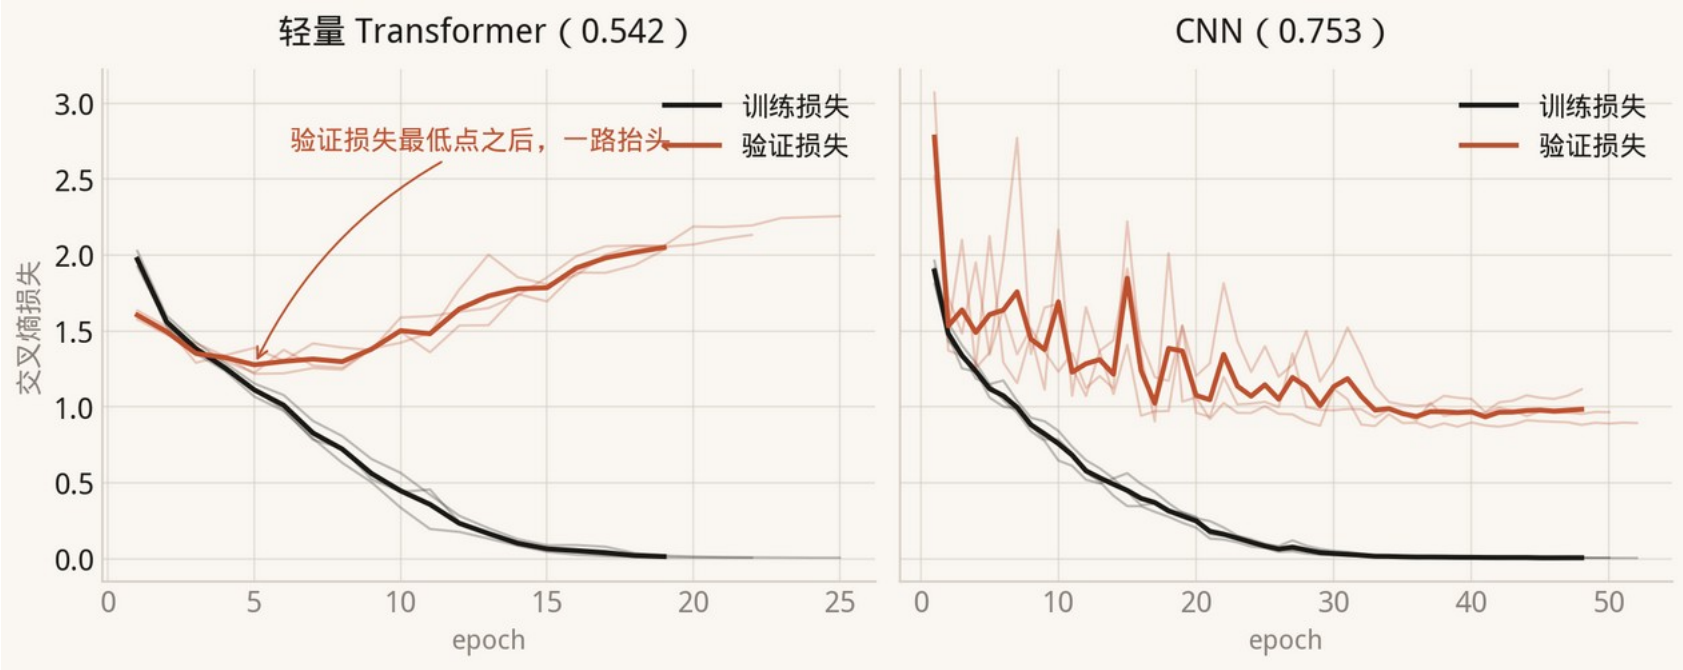
先验越少，越吃数据

0.753 > 0.723 ≫ 0.542	GTZAN 985 首：CNN 赢，轻量 TF 差 21 个点
0.492 > 0.470	FMA 8 倍数据：CRNN 反超 CNN
0.814 / 0.590	同一个 Transformer 架构，预训练后两榜第一

问题不在架构，在数据与先验。

来源：results/gtzan/metrics.csv · results/fma/metrics.csv

那条过分自信的曲线

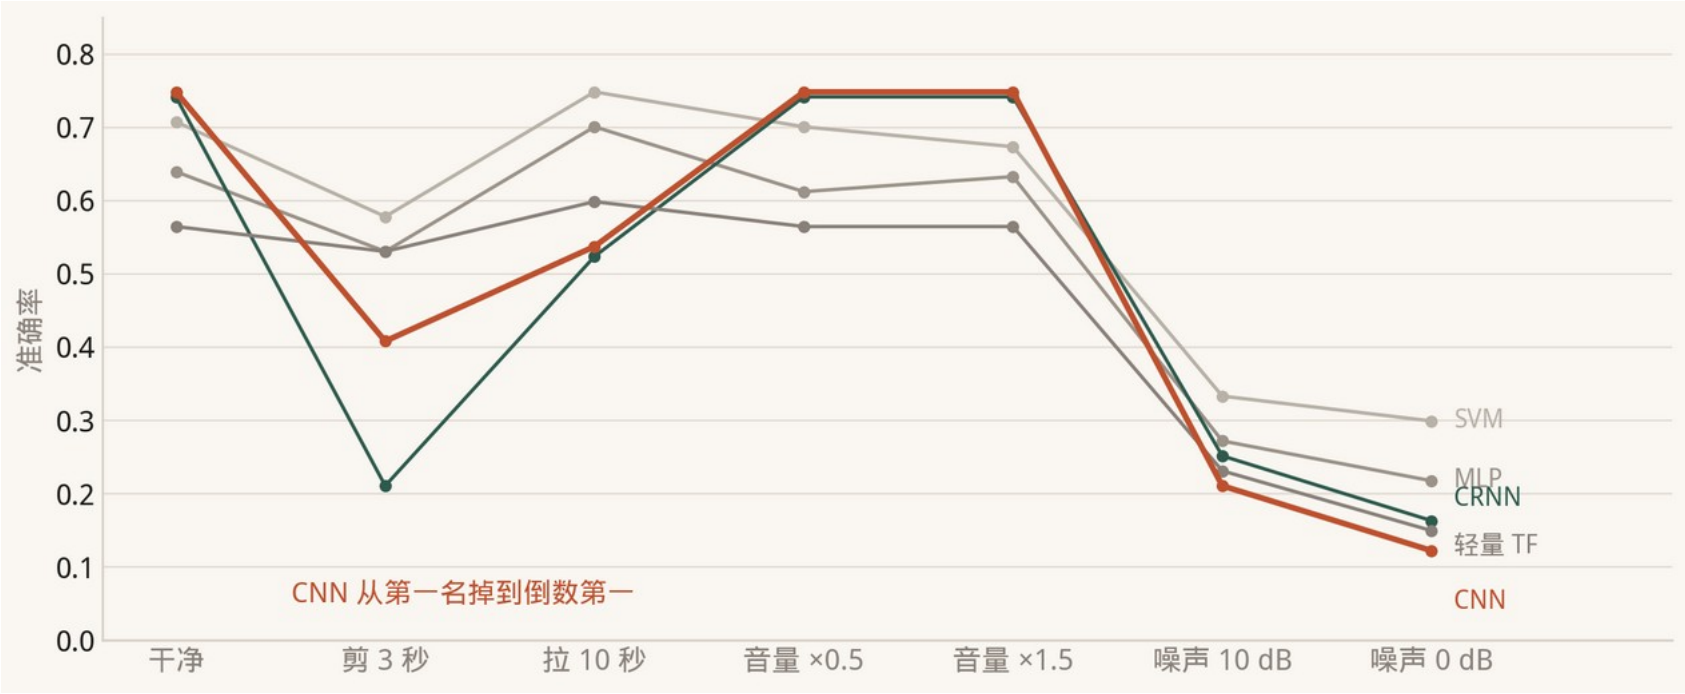


GTZAN 训练 / 验证损失（细线为三个种子，粗线为均值）

30 轮加到 60 轮：GTZAN +0.75 / +1.36，FMA −0.5 左右 —— 再训也这样。

来源：results/logs/overnight/*.log · 报告 §5.3 表 13

换个听法就翻车



七种扰动下的准确率（n=147，不重新训练；seed 42 权重）；剪成 3 秒时 CRNN 掉 53.1 点、SVM 只掉 12.9 点

0 dB 噪声下 CNN 从第一名掉到倒数第一：0.748 → 0.122，掉 62.6 个点；同一条件下 SVM 只掉 40.8 个点。

来源：results/gtzan/robustness.csv（35 行）

能拧的旋钮，都拧过了

试过什么	结果
SpecAugment + 标签平滑	FMA 上最大 +0.7 个点，落在种子波动内
30 轮 → 60 轮	两个数据集互有胜负
学习率 / 批大小扫描	无稳定收益

剩下的差距，不是调参能补的。

来源：报告 §5.3 表 13

它知道这是什么。

它不知道接下来会响什么。

p(流派 | 音频) → p(下一个 Token | 前 5 秒)

把声音拆成符号

采样率	32 kHz
帧率	50 Hz（每帧 20 ms）
码本	4 个
每帧符号	4 个 Token

「预测音频」变成「预测下一个符号」——交叉熵直接能用。



残差矢量量化：第 1 个码本画轮廓，后 3 个逐级补细节 → 串成整数序列

来源：报告 §6.2

两条流水线

5 秒前缀 → 4×250 Token → 1 秒 · 4×50 Token　① 自己训的小模型

5 秒前缀（波形） → 3 秒波形　② MusicGen-small + 我们的 LoRA

① 指标	下一个符号猜对没有（ Top-1 ）
② 指标	频谱离真实多远（ Log-Mel RMSE ）

这两个数不能互相比，也不能跟分类的 0.814 比。

来源：报告 §3.6 · §6.2

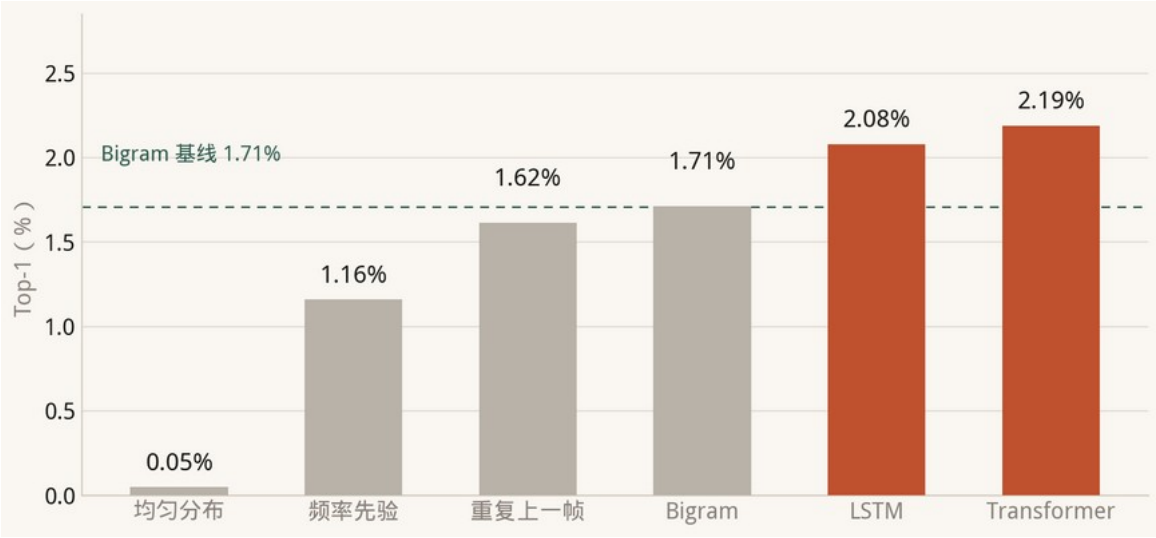
先立四个「笨」基线

基线	做法	Top-1
均匀分布	词表内等概率瞎猜	0.049%
频率先验	永远猜训练集最高频符号	1.16%
Persistence	把上一帧原封不动重复一遍	1.62%
Bigram	数相邻符号谁跟着谁	1.71%
我们的模型	Transformer / LSTM	**2.19% / 2.08%**

打不过 Persistence，就说明它在假装学习。

来源：results/token_prediction_long/metrics.csv

学会了，但只学会一点点



free-running Top-1（3 种子均值）

3.36%

看着答案考试（teacher-forced）

2.19%

自己往下接（free-running）

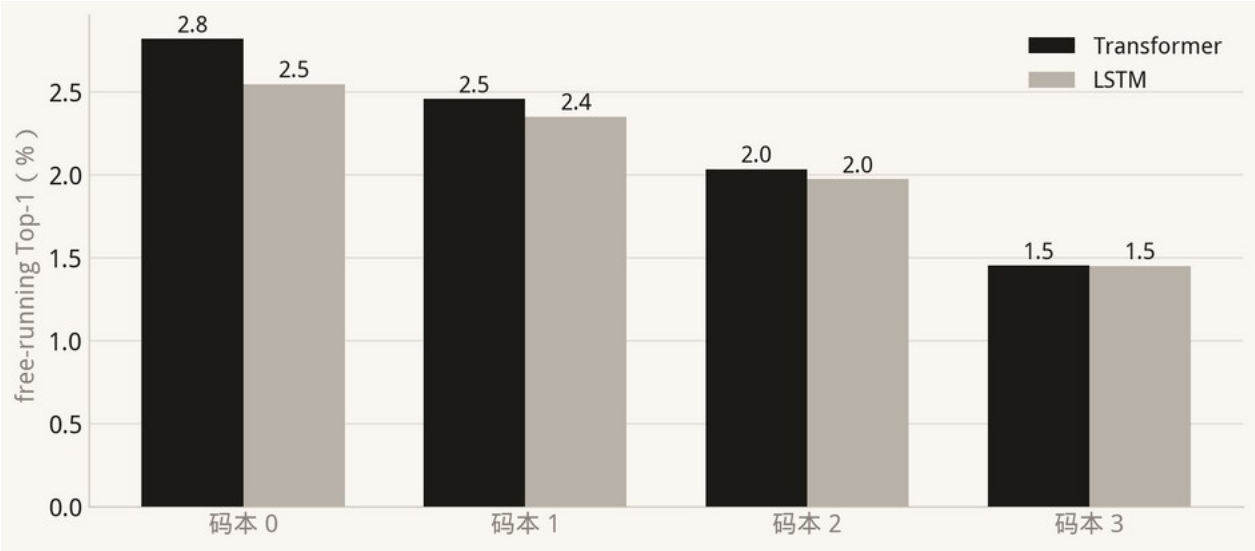
−35%

一步之差

2.19% 是瞎猜的 45 倍，也是一百个符号里猜对两个。

来源：results/token_prediction_long/metrics.csv

码本也有难易之分



四个码本各自的 free-running Top-1

码本 0 → 码本 3	2.8% → 1.5%，由粗到细逐级下降
这说明	结构对得上 RVQ；如果是在瞎猜，四个码本应该一样烂

来源：results/token_prediction_long/metrics.csv

请听四段

01

前缀

模型看到的 5 秒

02

真实

唱片里原本的后 3 秒

03

原始续写

MusicGen-small

04

适配后续写

+ LoRA r=8

段间隔 0.6 秒 · 000995 Experimental
0:16

20.85 → 17.19

Log-Mel RMSE · 八首里改善最大（− 3.65 ）

三条里只有一条是真的

同一段 5 秒前缀，只有后半段不同

0:00

A

0:08

0:00

B

0:08

0:00

C

0:08

揭晓答案

（点击或按页面说明口头公布）

三个文件已重命名，页面不显示原始文件名

这一条，改完反而更差

同样四段：前缀 → 真实 → 原始 → 适配
0:16

27.13 → 27.46

8 首测试曲里唯一退步的一首（ +0.33 ）

来源： demo/audio/README.md §4

最贵的一课：标签写错了

loss是什么情况
11.08错误布局：比均匀分布还差
5.46正确布局
7.62均匀分布（乱猜的上界）

症状	不报错， loss 只停在偏高的值上，看起来像「还没训够」
改对之后	19.23 → 17.91 ， 7/8 首改善， t = −3.36

来源：报告 §6.10

三个旋钮，全都不灵

配置	RMSE	相对原始配对检验
原始模型	19.23	——
LoRA r=8， 1200 步	**17.91**	**−1.32t = −3.36，显著**
LoRA 3600 步	17.71	−1.52t = −0.47，不显著
LoRA 全窗口	17.64	−1.59t = −0.33，不显著
LoRA r=16	18.59	−0.64t = −1.06，不显著

NLL 一直在降，音频距离没跟着降。

来源：报告 §6.9 / §6.11

为什么只有 3 秒

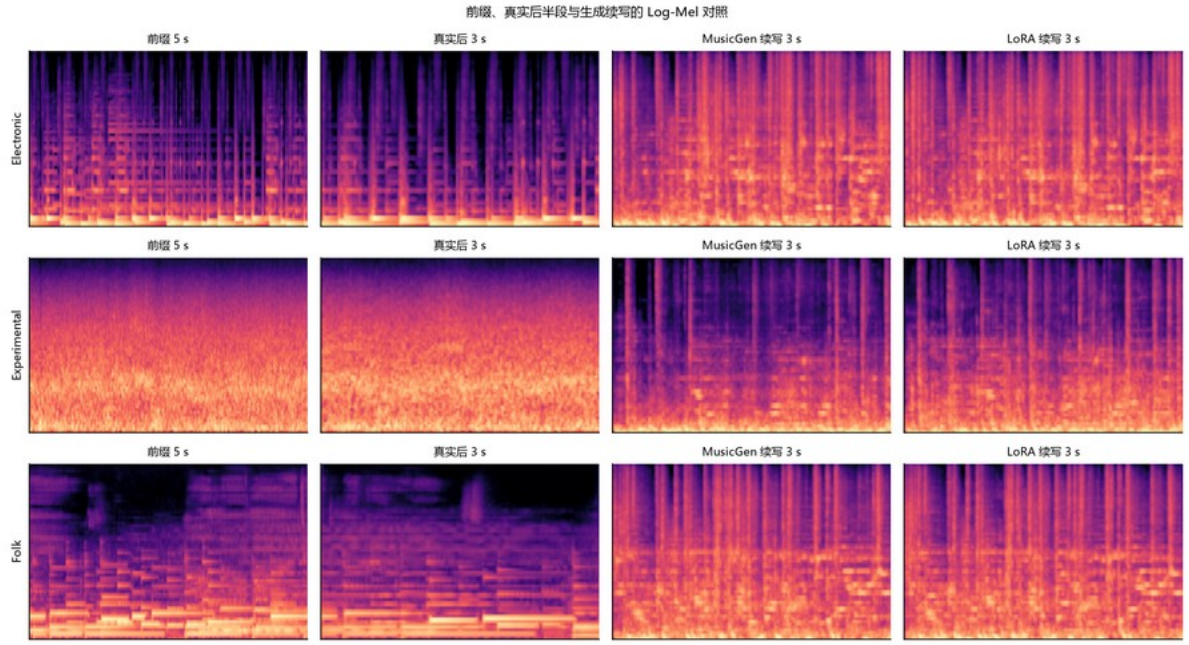
续写长度	耗时（RTX 4060）情况
3 秒	5.6 s8/8 曲目稳定，主结果口径
6 秒	16.3 s可生成
8 秒	18.3 s可生成
12 秒	35.4 s可生成
16 / 20 秒	–崩：位置索引越界

崩的原因不在长度： pad/bos 的 id 是 2048，而词表只到 2047 。

3 秒是「八首都能稳定跑完」的口径，不是能力上限。

来源： demo/README.md §3.5

指标不等于好听



前缀 | 真实 | 原始续写 | 适配后续写（Log-Mel）

指标

Log-Mel RMSE—— 离原曲多近

没做

规模化主观听感评分

所以我们只说「客观距离变近了」，不说「变好听了」。

来源：报告 §6.7 / §7.9

结案

- **判别式：最大的单点收益是预训练，不是架构**
- **模型排序会随数据规模翻转： 985 首 CNN 赢， 7,994 首 CRNN 反超**
- **泄漏能让结论虚高十个点： 0.470 → 0.568**
- 生成式：能预测，学得很少，修好对齐后有可测改善，三个旋钮无效

五个负结果都留在报告里：正则化无效 · 轻量 TF 小数据崩 · 噪声下 CNN 垫底 · LoRA 初版失效 · 三旋钮无效

我们没把「跑通」当成「做好」。