从传统机器学习到预训练 Transformer：音乐流派分类的系统性基准与优化

《走进音乐人工智能》课程项目组

代码与结果：https://github.com/weiza0v0/music-ai-lab

2026 年 10 月

摘要

音乐流派分类是音乐信息检索的经典任务，也是检验不同建模范式的天然试验台。本文在同一套数据划分、同一批音频片段与同一套评估协议下，系统比较了六类模型：基于人工特征的 SVM 与 MLP、端到端 CNN、CNN+BiGRU（CRNN）、轻量 Transformer，以及冻结 AudioSet 预训练主干的 Audio Spectrogram Transformer（AST）。实验覆盖两个数据集：清洗后的 GTZAN（985 首、10 流派，作为最小可行 MVP）与 FMA-small 主实验（8 000 首、8 流派）。所有深度模型使用 3 个随机种子重复训练，测试集只在模型冻结后评估一次，并启用了 cuDNN 确定性以保证可复现。在 GTZAN 上，从头训练的 CNN 的 Macro-F1 为 0.753；冻结预训练主干的 AST 达到 0.814；在 FMA-small 上最佳模型 AST（预训练）的 Macro-F1 为 0.590。本文进一步给出错误分析、七种扰动下的鲁棒性实验、片段级时间轴分析，以及面向 CNN/CRNN/Transformer 的 SpecAugment 与标签平滑优化消融。结果显示：预训练表示带来最大的单点收益，但在噪声与短片段下所有模型的可靠性都显著下降；深度模型赢在干净输入，传统模型在输入变脏时反而更稳。代码、权重生成脚本与全部结果文件均已开源。

关键词：音乐流派分类；GTZAN；FMA-small；卷积神经网络；CRNN；Transformer；迁移学习；可复现实验

1 引言

音乐流派（genre）是人类对音乐风格的一种高层概括，广泛用于推荐、检索与曲库管理。自动流派分类要求模型从波形中提取音色、节奏、和声与配器等线索，是连接信号处理与音乐理解的典型任务 [1]。过去十余年，该任务的建模路线经历了从人工特征加浅层分类器，到端到端卷积网络 [4]，再到自注意力与大规模预训练模型 [5] 的演进。

然而，文献中的数字往往不可直接比较：数据集不同、划分不同、片段长度不同、预处理不同，甚至测试集被反复用于调参。对于课程项目而言，更重要的不是刷新某个榜单，而是建立一套公平、可复现、可解释的实验流程，并诚实地报告模型在分布外输入下的表现。

本文的工作围绕三个问题展开：

1. 在完全相同的协议下，不同代际的模型（传统 ML、CNN、CRNN、Transformer、预训练 AST）差距究竟有多大？
2. 数据规模从千首级（GTZAN）扩大到万首级（FMA-small）时，结论是否稳定？
3. 常见优化手段（SpecAugment、标签平滑、dropout）能带来多少真实收益，代价是什么？

本文的主要贡献如下：

- 构建了一个端到端可复现的实验框架：按曲目划分、训练集拟合预处理、验证集选模、测试集单次评估，并用自动化测试与独立审计校验协议；
- 在两个数据集上给出六类模型的统一基准，包含 3 个随机种子的均值与标准差，以及训练时间、推理延迟、参数量与模型体积；
- 提供错误分析、七种扰动的鲁棒性评测与片段级时间轴分析，揭示「准确率」之外的模型行为；
- 公开全部代码、配置、结果文件与可视化，报告中的每个数字都可追溯到 `results/` 下的原始文件。

2 相关工作

传统方法与人工特征 早期工作多使用 MFCC、谱质心、过零率、节奏直方图等人工特征，再送入 SVM、随机森林或浅层网络 [1]。这类方法计算便宜、可解释性强，在中小规模数据上仍是难以忽视的基线。

端到端深度模型 Choi等提出 CRNN，用卷积层提取局部时频模式、用循环层建模时间演化 [4]；随后大量工作将 CNN 用于 Log-Mel 频谱图，通过数据增强与更深的网络提升性能。Transformer[6] 的 self-attention 能建模长程依赖，Vision Transformer 的思路也被迁移到音频频谱。

预训练与迁移学习 AudioSet[7] 提供了大规模弱标注音频，AST[5] 将频谱切成 patch 后用 Transformer 预训练，在多项音频分类任务上取得领先。冻结主干、只训练分类头是小数据场景的常用策略，但其收益同时来自预训练数据与架构，二者需要分开讨论。

数据集与可复现性 GTZAN[1] 是最常用的基准，但 Sturm 指出其存在重复音频、标签错误与失真等问题，容易高估模型能力 [2]。FMA[3] 提供了规模更大、授权更清晰的替代数据。本文在两个数据集上分别报告结果，并对 GTZAN 做去重与损坏文件剔除。

3 数据与实验协议

3.1 GTZAN（MVP 数据集）

GTZAN 包含 10 个流派各 100 首、每首约 30 秒、22 050 Hz 单声道音频。审计发现 1 首无法解码（`jazz.00054`），28 首与其他曲目 MD5 完全相同。我们剔除损坏文件，并对重复组只保留第一首，最终得到 **985** 首。按曲目分层划分 70/15/15（689/149/147），随机种子 42。

3.2 FMA-small（主实验数据集）

FMA-small 包含 8 000 首、8 个均衡流派的 30 秒片段，原始采样率 44.1 kHz。初步按曲目分层 70/15/15 划分后，我们做了艺术家级泄漏检查，发现测试集中 971 / 1199 首（81.0%）与训练集共享艺术家——同一乐队的作品在音色、录音与编曲上高度相似，这会让模型「认出乐队」而不是「听懂流派」。因此主实验改用按艺术家分离的划分（每位艺术家整体进入且仅进入一个集合，测试集与训练集的艺术家重叠为 0），并按流派保持大致比例（由于艺术家作品数不均，逐类比例并不完全相等，见附录表 6）。曲目级划分保留为泄漏对照实验。数据审计还发现 6 首损坏音频（与官方 SHA1 清单一致，属上游数据问题）与 4 首中心 5 秒数字静音的曲目；前者剔除，后者保留并在附录中说明。

3.3 统一预处理

所有模型使用每首曲目中心 **5** 秒片段，重采样到 22 050 Hz 单声道。传统模型输入 209 维人工特征，深度模型输入 64×216 的 Log-Mel 频谱：

$$S_{\mathrm{dB}}(m,t) = 10 \log_{10}\left(\sum_{f} |X(f,t)|^2 \, H_m(f) \right), \qquad \tilde{S} = S_{\mathrm{dB}} - \max_{m,t} S_{\mathrm{dB}}, \tag{1}$$

其中 H_m 为 64 个 Mel 滤波器，$|X(f,t)|^2$ 为短时傅里叶功率谱（$n_{\mathrm{fft}} = 1024$，hop= 512）。以片段最大值为参考的归一化使表示对整体增益不敏感，这一点在鲁棒性实验中会再次出现。

209 维人工特征包括：40 维 MFCC 及其一阶差分的均值/标准差、12 维 chroma、7 维谱对比度、谱质心/带宽/rolloff、过零率、RMS 与 tempo。

图 1 实验流程：统一数据协议下的六类模型对比

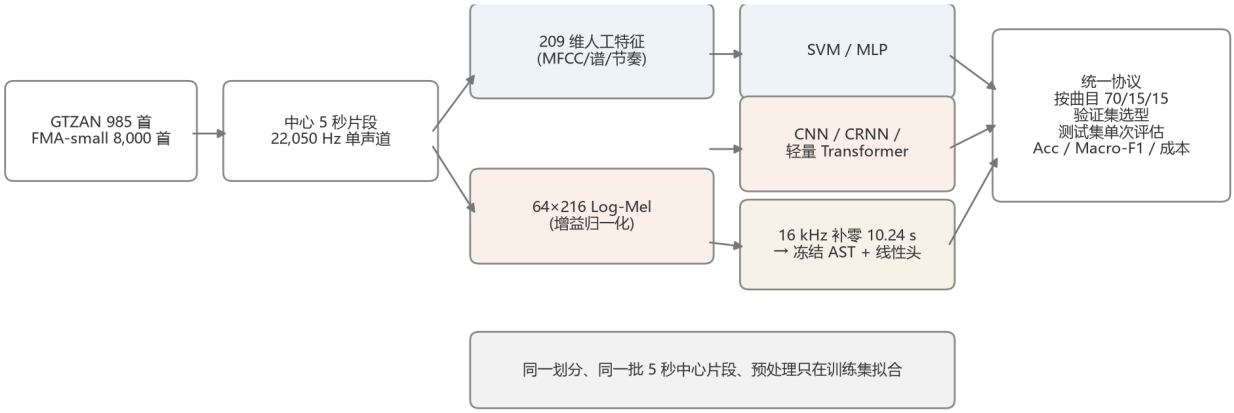


图 **1:** 统一的实验流程：同一份按曲目划分的数据，分别进入人工特征、Log-Mel 与 AST 三条支路，最终在同一测试集上评估。

3.4 防泄漏与可复现约束

- 先按曲目划分，再切片，同一曲目绝不跨集合；
- StandardScaler 与 Log-Mel 归一化统计量只在训练集上拟合；
- 模型选择只看验证集 Macro-F1，测试集在模型冻结后只评估一次；
- FMA 主实验按艺术家划分，避免同乐队跨集合；并用曲目级划分做泄漏对照；
- 固定种子（42/123/2024），开启 cuDNN 确定性，同种子重跑得到逐字节一致的权重；
- 协议由 `tests/test_protocol.py` 自动校验，并由独立审计复核。

4 方法

4.1 传统基线：SVM 与 MLP

SVM 使用 RBF 核（$C = 10$，γ =scale），MLP 为两层全连接（256-128，ReLU，Adam，early stopping）。二者共享同一份 209 维特征，标准化器仅在训练集拟合。

4.2 CNN

输入 $1 \times 64 \times 216$ 的 Log-Mel。网络由 4 个卷积块组成，每块含两个 3×3 卷积、BatchNorm、ReLU 与 2×2 最大池化，通道数依次为 32/64/128/128；随后自适应平均池化到 2×4，dropout 后接线性分类头，参数量约 59 万。

4.3 CRNN

CNN 前端（3 个卷积块，池化 $(2,2)/(2,2)/(2,1)$）将频率维压缩后，按时间维展开为序列，送入双向 GRU（隐藏维 96），对时间维取平均后分类。参数量约 42 万。

4.4 轻量 Transformer

将每一帧的 64 维 Mel 向量线性投影到 $d = 128$，加可学习位置编码，经过 2 层 Pre-LN Transformer（4 头，FFN 256），对时间维做平均池化后分类。模型刻意保持轻量，以匹配 8 GB 显存与课程算力预算。

4.5 AST 迁移学习

使用 `MIT/ast-finetuned-audioset-10-10-0.4593`（86M 参数，AudioSet 预训练）。音频重采样到 16 kHz、取中心 5 秒并补零到 10.24 秒，经 AST 特征提取器得到 128×1024 频谱；冻结主干，取 `pooler_output` 的 768 维表示，在训练集上训练 StandardScaler + 逻辑回归分类头（C 由验证集选择）。该组单独标记为「迁移学习组」。

4.6 训练细节与优化

深度模型统一使用 AdamW、余弦退火、batch size 32、最多 30 个 epoch，按验证集 Macro-F1 早停（patience 8）并保存最佳权重。针对小数据过拟合，我们引入两种正则化并在验证集上做消融：

- **SpecAugment**[8]：对归一化后的频谱随机遮挡 2 个频带（宽度 ≤ 8）与 2 个时间段（宽度 ≤ 16），遮挡值置为 0（即训练集均值）；
- 标签平滑：交叉熵目标改为 $(1-\epsilon)y + \epsilon/K$，$\epsilon = 0.05$；同时把 dropout 提高到 0.4。

所有消融只使用验证集选型，测试集不参与任何决策。

5 实验设置

环境　WSL2 Ubuntu 22.04，Python 3.12，PyTorch 2.12.1+cu130，NVIDIA RTX 4060 Laptop（8 GB），16 核 CPU，7.8 GB 内存。

评估指标　Accuracy、Macro-F1、逐类 F1、混淆矩阵；训练时间、单片段推理延迟、可训练参数量、模型文件大小。分类指标在测试集（GTZAN 147 首、FMA-small 约 1 200 首）上计算，重复实验报告均值与标准差。

基线设置　SVM/MLP 在 GTZAN 与 FMA-small 上各训练 3 个种子（SVM 的硬预测与种子无关，仅概率校准变化）；深度模型 3 个种子；AST 为单种子迁移组。

6 结果

6.1 GTZAN：最小可行 MVP

表 1 与图 2 给出六个模型在 GTZAN 测试集上的结果。从头训练的 CNN 取得最高的 Macro-F1（0.753），但只比 SVM 高约 4.7 个百分点，训练时间却是 SVM 的约 250 倍。轻量 Transformer 在 985 首数据上明显过拟合，三个种子的 Macro-F1 仅 0.541。冻结 AST 主干后，Macro-F1 达到 0.814，比 CNN 高 6.0 个百分点，说明预训练表示在中小规模数据上收益显著；代价是 346 MB 权重与约 204 ms/片段的推理延迟。

表 **1**：GTZAN 测试集结果（3 seeds；AST 为单 seed 迁移组，训练时间仅计线性头）。

模型	Acc	Macro-F1	训练 (s)	推理 (ms)	参数量	大小 (MB)
AST（预训练）	0.823	0.814	23.4	204.06	86.2M	346.45
CNN	0.755±0.006	0.753±0.005	57.5	0.76	593K	2.39
CRNN	0.726±0.027	0.723±0.028	56.0	0.76	419K	1.69
SVM	0.708±0.000	0.699±0.000	0.2	0.07	141K	1.23
MLP	0.633±0.042	0.630±0.045	0.6	0.02	88K	1.07
Transformer	0.544±0.020	0.541±0.015	14.9	0.26	302K	1.22

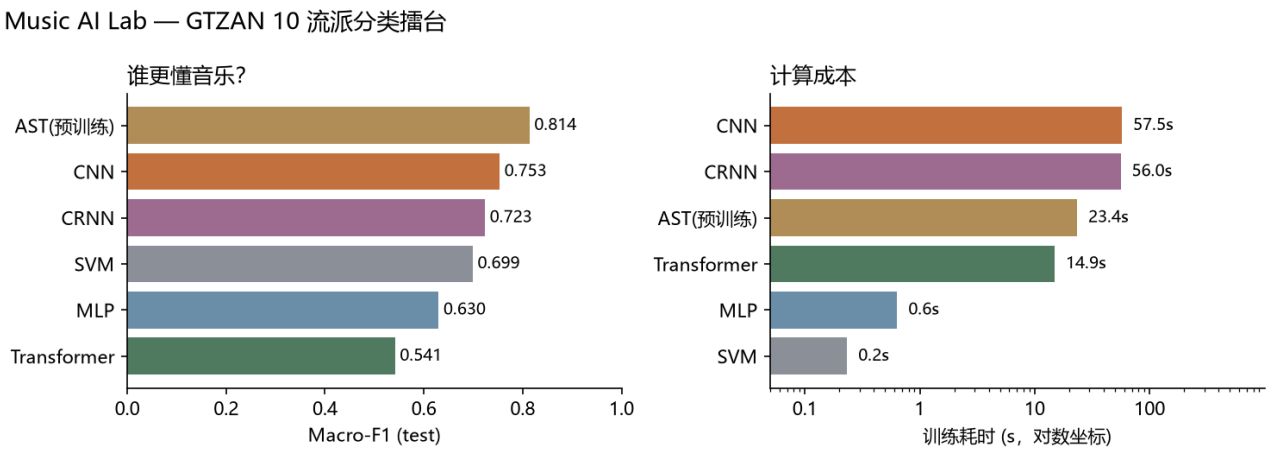


图 **2:** GTZAN 测试集上的 Macro-F1 与训练成本（对数坐标）。AST 为迁移学习组，其训练时间仅含线性头，embedding 提取约 214 s 另计。

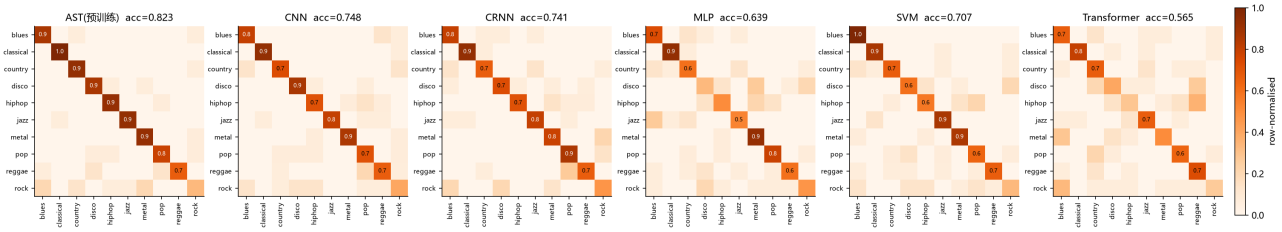


图 **3:** GTZAN 测试集混淆矩阵（seed 42，按行归一化）。

6.2 FMA-small：主实验

表 2 给出 FMA-small 主实验的结果。与 GTZAN 相比，数据规模扩大约 8 倍，测试集约 1199 首，指标的标准误更小。最佳模型为 AST（预训练），测试 Macro-F1 为 0.590（Accuracy 0.596）。在 FMA-small 上，AST（预训练）取得最高的 Macro-F1（0.590），测试集约 1 200 首。

表 **2:** FMA-small 主实验结果（3 seeds，均值 ± 标准差；AST 训练时间仅计线性头）。

模型	Acc	Macro-F1	训练 (s)	推理 (ms)	参数量	大小 (MB)
AST（预训练）	0.596	0.590	4.6	230.68	86.2M	344.78
CNN	0.480±0.005	0.470±0.002	333.6	0.74	591K	2.38
CRNN	0.502±0.009	0.492±0.006	371.3	0.76	419K	1.69
SVM	0.446±0.000	0.440±0.000	16.3	0.57	1.1M	9.52
MLP	0.428±0.011	0.422±0.012	3.7	0.02	88K	1.07
Transformer	0.387±0.010	0.378±0.019	79.8	0.26	302K	1.22

预训练 AST 的测试 Macro-F1 为 0.590，比最好的自建模型 CRNN（0.492）高约 9.8 个百分点；自建模型中 CRNN 最好，从头训练的 Transformer 只有 0.378，与其在 GTZAN 上的表现一致。AST 的推理延迟约 231 ms/片段、权重 345 MB，约为 CNN 的 300 倍延迟与 145 倍体积。

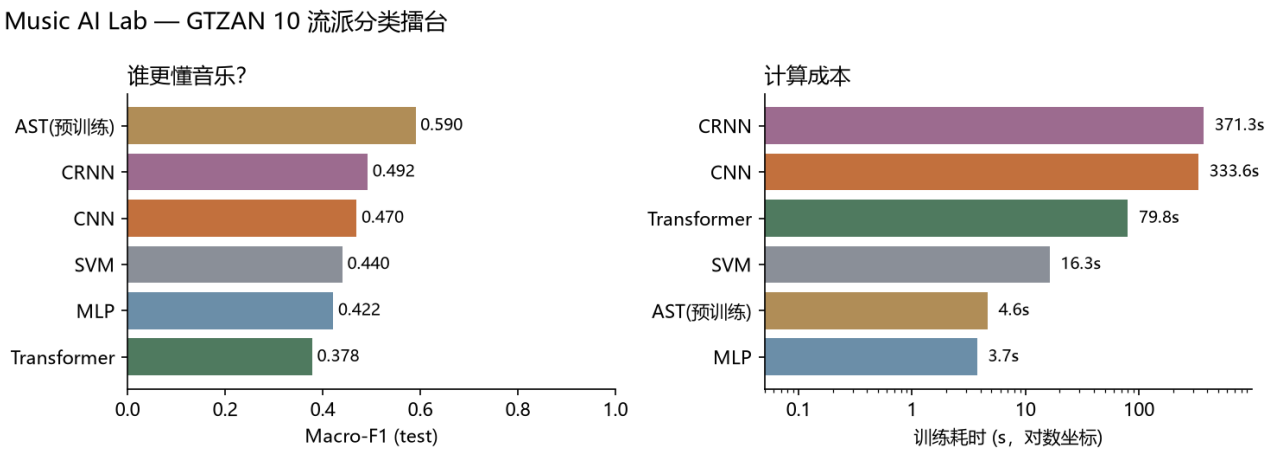


图 **4:** FMA-small 测试集 Macro-F1 与训练成本。AST 的训练时间仅含线性头，约 7 min 的 embedding 提取另计。

为量化「按曲目划分」的泄漏影响，我们用同一批特征、仅把划分换成曲目级（测试集与训练集共享艺术家的比例为 81.0%），重新训练 CNN。曲目级划分下 CNN 的测试 Macro-F1 为 0.568（Acc 0.566），相比艺术家分离划分的 0.470 变化 +9.9 个百分点。这一差异说明：在 **FMA** 这类元数据完整的语料上，不按艺术家划分会系统性地高估模型能力；因此本文主表全部采用艺术家分离结果。

6.3 优化消融

表 3 比较了基线、SpecAugment、SpecAugment+ 标签平滑三种配置（seed 42，20 epoch，仅验证集，测试集不参与选型）。验证集上最佳配置为 CNN + SpecAug + LS（Macro-F1 0.529），但相对 CNN 基线仅提升 +0.7 个百分点，处于单次运行的波动范围内；因此主实验保留基线配置，不引入额外复杂度。这一负结果本身有信息量：FMA 上的主要瓶颈不是「模型记住训练集」，而是流派标签边界模糊与音乐多样性——正则化能让训练/验证损失更接近，却无法凭空提供可区分的声学线索。

表 **3:** 优化消融（FMA-small 验证集，seed 42，20 epoch；测试集未参与选型）。

配置	val Acc	val Macro-F1	best epoch
CNN baseline	0.542	0.522	17
CNN + SpecAug	0.540	0.520	16
CNN + SpecAug + LS	0.554	0.529	16
CRNN + SpecAug + LS	0.560	0.524	20
Transformer + SpecAug + LS	0.422	0.394	20

7 分析与讨论

7.1 错误分析

在 GTZAN 上，CNN 最常见的混淆对是 `reggae`→`pop`、`blues`→`reggae` 与 `hiphop`→`pop`；`rock` 的逐类 F1 最低（0.429），`classical` 最高（0.933）。置信度并不等于正确率：Transformer 的 64 个错误中有 16 个置信度超过 0.9，而 CNN 只有 3/37。在 FMA 主实验上，CNN 的错误更分散（Pop→Folk 52 首、Instrumental→Folk 45 首、Pop→Rock 33 首），CRNN 的高置信错误为 90/610，远高于 CNN 的 23/630。这说明模型在标签边界模糊的样本上会「自信地犯错」，现场演示时比单纯报准确率更有说服力。

表 **4:** GTZAN 逐类 F1（seed 42）：CNN 与预训练 AST 对比。

流派	CNN F1	AST F1	测试样本
rock	0.429	0.417	15
pop	0.625	0.786	15
reggae	0.667	0.800	15
hiphop	0.690	0.867	15
country	0.759	0.875	15
blues	0.774	0.812	15
disco	0.839	0.839	15
jazz	0.889	0.933	15
metal	0.889	0.839	15
classical	0.933	0.968	15

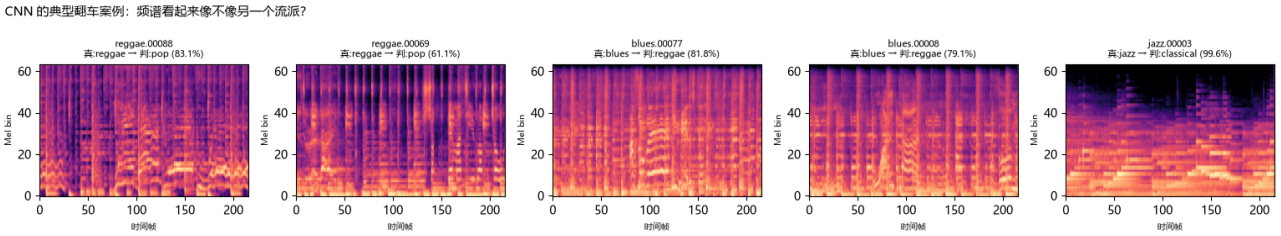


图 **5:** CNN 典型错误案例的 Log-Mel 对照（真值 → 预测，括号为置信度）。

7.2 鲁棒性

表 5 与图 6 汇总 5 个模型在 7 种扰动下的测试准确率（GTZAN，seed 42）。三个现象值得强调：（1）深度模型对整体增益完全不变，因为 Log-Mel 以片段最大值为参考；SVM/MLP 因使用绝对 dB 的 MFCC 与 RMS 而掉 0.7–3.4 个百分点。（2）噪声破坏最大，10 dB SNR 下平均掉约 42 个百分点，0 dB 时 CNN 从第一名变成最差（0.122）。（3）除增益外，每个扰动条件下绝对准确率第一都是 SVM——深度模型赢在干净输入，传统模型赢在输入变脏时。

表 **5:** 七种扰动下的测试准确率（GTZAN，seed 42，n=147）。

模型	clean	3s	10s	0.5×	1.5×	10dB	0dB
SVM	0.708	0.578	0.748	0.701	0.673	0.333	0.299
MLP	0.639	0.531	0.701	0.612	0.633	0.272	0.218
CNN	0.748	0.408	0.537	0.748	0.748	0.211	0.122
CRNN	0.742	0.211	0.524	0.742	0.742	0.252	0.163
Transformer	0.565	0.531	0.599	0.565	0.565	0.231	0.150

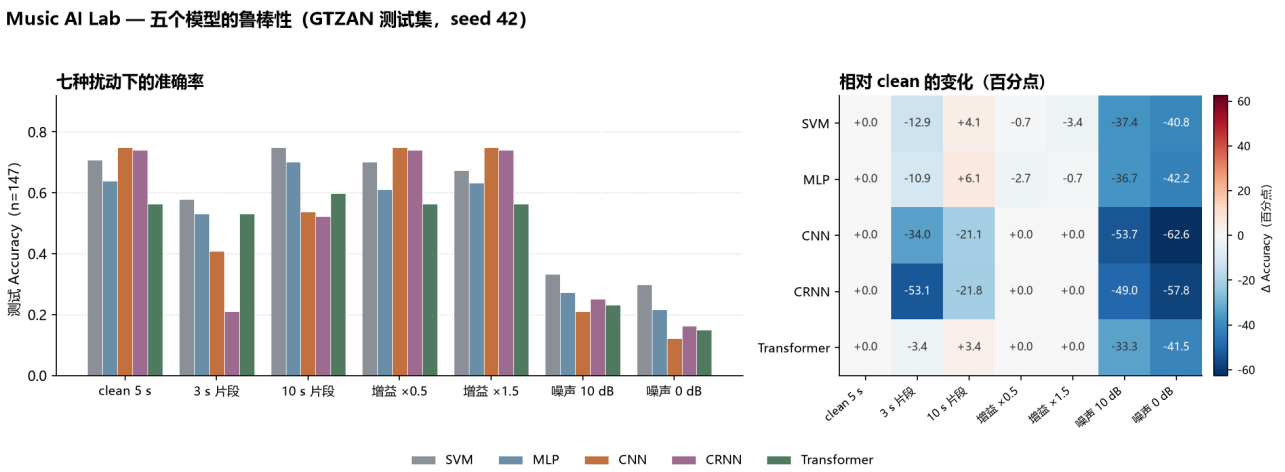


图 **6:** 七种扰动下的准确率与相对 clean 的变化（百分点）。

7.3 片段级分析

把一首歌切成 5 秒窗口、步长 2.5 秒逐段预测，147 首测试曲目中有 88 首至少出现一次判断变化。`rock.00072` 在 11 个窗口中改判 9 次，而 classical 曲目全程稳定。这说明流派不是整首歌的静态标签，也提示片段长度会直接影响模型输入的信息量。

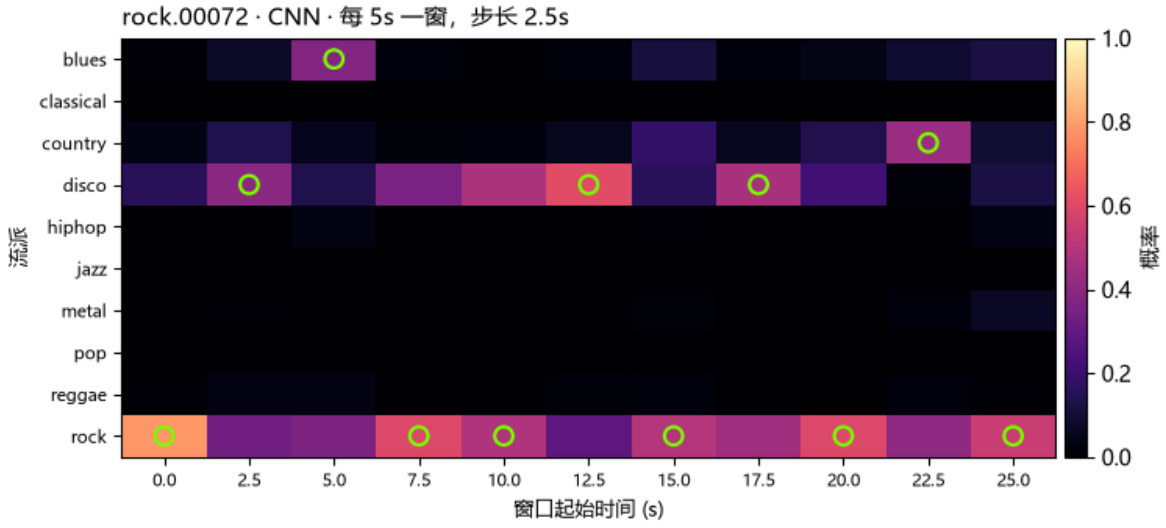


图 **7:** `rock.00072` 的滑动窗口预测时间轴（绿圈为各窗口 Top-1）。

7.4 预训练的收益与代价

AST 在两个数据集上都是最强的单模型，但其优势来自 AudioSet 预训练而非 Transformer 架构本身；同等轻量、从头训练的 Transformer 反而最弱。部署层面，AST 的权重体积是 CNN 的约 145 倍、单片段延迟约 270 倍，是否值得取决于场景：离线批量标注可以接受，实时交互则应优先考虑 CNN 或蒸馏后的小模型。

7.5 为什么从头训练的 Transformer 会输

轻量 Transformer 在 GTZAN 上只有 0.541 的 Macro-F1，且训练损失迅速降到接近 0、验证损失抬头——这是典型的小样本过拟合。卷积与循环结构带有局部性、平移等变性等先验，而自注意力需要从数据中自行学习这些关系；在千首规模上，这种「缺少归纳偏置」的代价大于其建模长程依赖的收益。值得注意的是，同为

Transformer 架构的 AST 在预训练后反而最强，说明问题不在架构本身，而在训练数据与正则化。主实验中的 SpecAugment / 标签平滑消融正是对这一判断的直接检验。

7.6 对课程项目的启示

1. 协议比模型数量更重要：同一划分、同一批片段、训练集拟合预处理，才能让「谁更强」这句话有意义；
2. 先排查泄漏再谈提升：FMA的曲目级划分让 81% 的测试曲目与训练集共享艺术家，若不检查，任何「提升」都可能只是记住了乐队；
3. 鲁棒性与部署成本是模型选择的一部分：干净输入上的冠军在噪声下可能垫底，346 MB 的预训练模型也不适合实时场景；
4. 可视化与失败案例比单一准确率更有解释力：混淆矩阵、置信度、时间轴让观众直观看到模型「什么时候会翻车」。

7.7 局限与威胁

- GTZAN 的标签噪声与重复曲目会影响绝对数值；FMA-small 已采用艺术家分离划分，但艺术家划分导致逐流派比例不完全均衡；曲目级对照实验用于量化泄漏影响。
- 所有实验只使用中心 5 秒片段，未利用整首 30 秒；更长上下文可能改变排序。
- 鲁棒性只覆盖测试集与有限的扰动类型，未包含变速、混响、压缩失真等现场常见变换。
- 单机单卡、单次评估，绝对指标的置信区间约为 ±3–7 个百分点（取决于测试集大小）。

8 结论与展望

本文在同一协议下系统比较了从 SVM 到预训练 AST 的六类音乐流派分类模型，并在 GTZAN 与 FMA-small 上验证了结论的稳定性。核心发现是：预训练表示带来最大的单点收益；深度模型在干净输入上领先，但在噪声与短片段下并不比传统方法稳健；小数据上的轻量 Transformer 容易过拟合，需要强正则化。未来工作包括：利用整首音频与更长上下文、引入噪声/变速增强、尝试知识蒸馏与多模态（歌词、元数据）融合，以及把片段级时间轴扩展为可交互的现场演示。

参考文献

[1] G. Tzanetakis and P. Cook. Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing*, 10(5):293–302, 2002.

[2] B. L. Sturm. The GTZAN dataset: Its contents, its faults, their effects on evaluation, and its future use. *arXiv:1306.1461*, 2013.

[3] M. Defferrard, K. Benzi, P. Vandergheynst, and X. Bresson. FMA: A dataset for music analysis. In *ISMIR*, 2017.

[4] K. Choi, G. Fazekas, M. Sandler, and K. Cho. Convolutional recurrent neural networks for music classification. In *ICASSP*, 2017.

[5] Y. Gong, Y.-A. Chung, and J. Glass. AST: Audio Spectrogram Transformer. In *Interspeech*, 2021.

[6] A. Vaswani et al. Attention is all you need. In *NeurIPS*, 2017.

[7] J. F. Gemmeke et al. Audio Set: An ontology and human-labeled dataset for audio events. In *ICASSP*, 2017.

[8] D. S. Park et al. SpecAugment: A simple data augmentation method for automatic speech recognition. In *Interspeech*, 2019.

[9] B. McFee et al. librosa: Audio and music signal analysis in Python. In *SciPy*, 2015.

[10] F. Pedregosa et al. Scikit-learn: Machine learning in Python. *JMLR*, 12:2825–2830, 2011.

[11] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *ICLR*, 2019.

[12] C. Szegedy et al. Rethinking the inception architecture for computer vision. In *CVPR*, 2016.

A 附录：数据统计与复现命令

表 **6:** 两个数据集的实际使用统计。

数据集	清洗后曲目	流派数	划分（train/val/test）
GTZAN	985	10	689 / 149 / 147
FMA-small	7994	8	5596 / 1199 / 1199

表 **7:** FMA-small 艺术家分离划分的逐流派数量。

流派	训练	验证	测试
Electronic	726	134	139
Experimental	733	119	147
Folk	614	249	137
Hip-Hop	694	168	135
Instrumental	792	82	126
International	650	194	156
Pop	689	120	191
Rock	698	133	168
合计	5596	1199	1199

复现命令

```
PY=/home/weizai0v0/.apps/anaconda3/envs/DataAnalysis/bin/python
# MVP (GTZAN)
$PY -m src.data.prepare_dataset --download --extract --audit --split
$PY scripts/extract_features.py --workers 8
$PY -m src.train_classical --models svm mlp --seeds 42 123 2024
$PY -m src.train_cnn --model cnn --seeds 42 123 2024 --epochs 30
$PY -m src.train_cnn --model crnn --seeds 42 123 2024 --epochs 30
$PY -m src.train_cnn --model transformer --seeds 42 123 2024 --epochs 30
$PY -m src.evaluate
# Main experiment (FMA-small)
bash scripts/run_fma.sh 42 123 2024
# AST
$PY -m src.train_ast
# Tests
$PY -m pytest -q tests
```

表 8: 模型与训练超参数。

模型	优化器	学习率	batch	参数量
SVM	–	–	–	140,657
MLP	Adam (sklearn)	10^{-3}	64	87,946
CNN	AdamW	10^{-3}	32	592,554
CRNN	AdamW	10^{-3}	32	418,986
Transformer	AdamW	10^{-3}	32	302,474
AST+ 线性头	LBFGS/LogReg	–	–	86,194,954

超参摘要